

修士論文概要書

Summary of Master's Thesis

Date of submission: 02/29/2026

専攻名(専門分野) Department	電気・情報生命	氏名 Name	渡邊 遼真	指導教員 Advisor	村田 昇
研究指導名 Research guidance	情報学習システム	学籍番号 Student ID number	5324E110-4		
研究題目 Title	マルチモーダルな GNN における説明可能な影響力予測				

研究背景

近年、スマートフォンおよびSNSの普及によりデジタルマーケティング市場は拡大しており、特にインフルエンサーマーケティングは企業の認知獲得や購買行動促進において重要な施策となっている。しかし、著名なトップインフルエンサーは起用コストが高騰し、競合との獲得競争も激しいため、早期に有望な人材を発掘し中長期で育成・契約する「青田買い」が実務上の鍵となる。

この意思決定を支えるため、SNS上の行動ログを用いて将来の影響力(例:エンゲージメント)を予測し、候補者をランクインする研究が進んでいる。一方で、多くの深層学習モデルは高精度でも予測プロセスがブラックボックスになりやすく、「なぜその人物が伸びると予測されたのか」という根拠が得られない。実務では、単に予測スコアが高いだけでは施策に結びつかず、投稿頻度・内容・関係性など、具体的に何が成長のドライバとなっているのかを説明可能な形で提示することが求められる。

そこで本研究は、時系列かつ異種混合(マルチモーダル)データに基づく影響力予測モデルに対して、予測と整合する説明を付与する枠組みを構築し、その妥当性と有用性を検証することを目的とする。

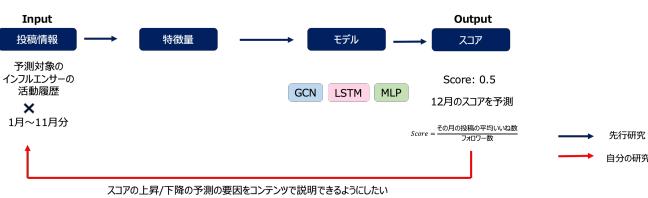


図1: 本研究の位置付け(予測モデルと説明手法の統合、および月次比較可能な寄与分析)

問題設定

本研究では、Instagramの投稿データ(画像・キャプション・ハッシュタグ等)とユーザー間の関係性(例:メンションやコメントの共起)を用い、月次の異種混合グラフ列を構築する。各時刻 t におけるグラフを

$$G_t = (V_t, E_t, \phi), \quad X_t \in \mathbb{R}^{|V_t| \times d}$$

とする。ここで V_t はノード集合(ユーザー、タグ、オブジェクト等)、 E_t はエッジ集合(例:ユーザー-タグ、ユーザー-メンションなど)、 ϕ はノード/エッジのタイプを表す。 X_t はノード特徴行列であり、数値特徴(投

稿数・投稿間隔・過去エンゲージメント統計)に加え、画像・テキストから抽出した特徴(例:画像輝度やテキスト長)など、マルチモーダル特徴を含む。

タスクは、過去 T 期間における入力 $\{(G_{t-T+1}, X_{t-T+1}), \dots, (G_t, X_t)\}$ から、次期における各ユーザー u の影響力スコア \hat{y}_u を推定し、上位ユーザーをランクインすることである。本研究の目的は値の回帰精度よりも「有望ユーザーの上位抽出」であるため、学習はLearning to Rankとして定式化し、順位の整合性を直接最適化する。

なお、本データセットは完全なフォロー関係を含まないため、関係性はメンション等の代替指標により近似する。したがって、構築されるネットワークは「眞の社会関係」を完全に反映するものではなく、観測可能な相互作用に基づく近似である。本研究ではこの制約を明示した上で、予測と説明の枠組みの検証を行う。

提案手法

本研究は、(1) 時系列・異種混合グラフに基づく影響力予測(InfluencerRank型)と、(2) 最適化ベースのマスク学習による説明(MaskOpt)を統合する枠組みを提案する。目的は、単に「誰が伸びるか」を当てるだけでなく、「なぜ伸びると判断したのか」を特徴量および関係性(エッジ)レベルで提示し、月次比較可能な形に整えることである。

(1) 予測モデル: InfluencerRank型 各月の異種混合グラフ G_t に対してGNN(例:GCN)を適用し、ユーザー u の表現 $h_{u,t}$ を得る。

$$h_{u,t} = \text{GNN}(G_t, X_t; \theta_{\text{gnn}})$$

次に、過去 T 期間の表現列 $\{h_{u,t-T+1}, \dots, h_{u,t}\}$ をRNN(LSTM/GRU)で時系列統合し、隠れ状態 $s_{u,t}$ を更新する。

$$s_{u,\tau} = \text{RNN}(h_{u,\tau}, s_{u,\tau-1}; \theta_{\text{rnn}})$$

さらにTemporal Attentionにより各時刻の重要度 $\alpha_{u,\tau}$ を推定し、コンテキスト表現 $c_u = \sum_{\tau} \alpha_{u,\tau} s_{u,\tau}$ を得る。最後にMLPで将来スコア \hat{y}_u を出力し、このスコアでランクインを作る。この構成により、「どの月の状態が予測に効いたか」を注意重みとして解釈でき、後述の説明手法とも自然に接続できる。

(2) 説明手法: End-to-End マスク最適化 (MaskOpt) 予測モデルを固定した上で、説明対象ユーザー u と説

手法	NDCG@50	RBP(0.95)	Pearson
InfluencerRank	0.89	0.043	0.48
UA(投稿頻度)	0.49	0.024	0.09
DeepInf	0.56	0.031	0.23

明対象時刻（または時刻集合）を定め、入力要素に連續値マスクを導入する。具体的には、(i) ノード特徴量に対するマスク m^{feat} , (ii) 近傍エッジに対するマスク m^{edge} を学習し、マスク後の入力でも予測が大きく変化しない（忠実性）一方で、マスクが少数要素に集中する（簡潔性）ように最適化する。概念的には以下の目的関数を最小化する：

$$\mathcal{L} = \underbrace{\mathcal{L}_{\text{fidelity}}(\hat{y}_u^{\text{masked}}, \hat{y}_u^{\text{orig}})}_{\text{予測保持}} + \lambda_1 \|m^{\text{feat}}\|_1 + \lambda_2 \|m^{\text{edge}}\|_1$$

最適化後のマスク値を重要度 (importance) として用いる。重要度は「どの要素が選ばれたか」を表すが、符号（スコアを増やす/減らす方向）を含まないため、重要とされた要素を基準値へ置換したときの予測スコア差分を符号付き影響度 (score impact) として算出する。これにより、「何が重要か (importance)」と「どう効くか (score impact)」を分離して提示できる。なお、score impact は局所的な反実仮想量であり、因果効果の断定は行わない。

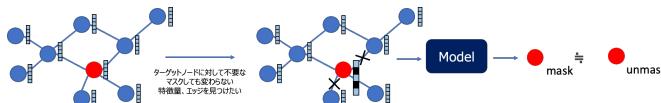


図 2: MaskOpt の概念図（予測を維持しつつ特徴量・エッジを疎に残すマスクを最適化）

解析例

ツールとしての信頼性を担保すべく、大きく 3 点の観点から解析を行った。

(1) 予測精度 (定量) 解析するにあたって、Instagram データセット（約 10 万ユーザー、2017 年 1 月～12 月）を用い、過去 11 ヶ月を学習用、12 月をテスト用とした。評価指標は NDCG@50 および RBP(0.95) を採用し、単純ベースライン（過去エンゲージメント統計に基づく順位付け）と比較した。表 1 に主要指標を示す。InfluencerRank 型モデルは単純ベースラインを上回り、将来有望ユーザーの上位抽出に有効であることを確認した。また、図 3 に予測スコアのヒートマップ例を示す。

相関分析においても、予測値と真の値が、ずれてい る部分はあれど、一定の精度で予測できていることが 図からわかる。

この結果から、予測モデルが妥当なランキング性能を示すことを確認した。フォロワー数、投稿頻度等の基本的な順位づけに加えて、他の影響度を予測する手法と比較しても高い性能を示すことから、インフルエンサー選定において有効なツールとなり得ることが示唆された。特に、過去のエンゲージメントの値を使用せずにコンテンツの特徴量や関係性に基づいて将来の影響力を予測できている点が重要である。Pearson 相

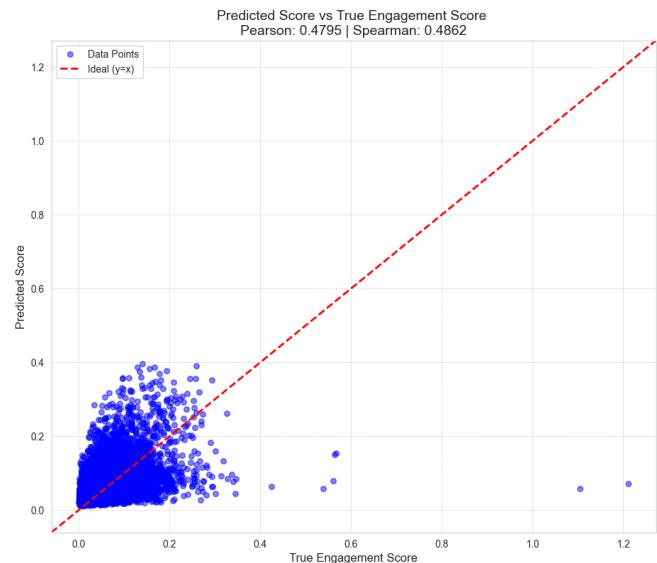


図 3: 集約例：importance ヒートマップ（プレースホルダ）。

関係係数の値も 0.48 付近を示し、一定の予測精度が得られている。よって、スコアの根拠を説明するための基盤として十分な性能を有していると判断した。

(2) 説明 (定性+忠実性) 分析の基となるモデルが妥当な予測を行うことを確認した上で、MaskOpt を適用し、重要特徴量・重要近傍を抽出していく。出力結果の例として以下の図が得られる。

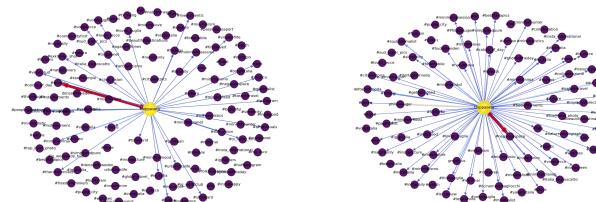


図 4: 1月のエッジ重要度 図 5: 3月のエッジ重要度

1 月、3 月のエッジ重要度可視化結果を図 4、図 5 に示す。この結果からそれぞれの月で重要な近傍エッジが異なることがわかる。さらに、重要特徴量・近傍を基準値に置換した際の score impact を算出し、説明の妥当性を定量的に検証した。実際に過去の投稿で使用された際に高いエンゲージメントが得られているのか、全く重要性が感じられない要素が選ばれていないか等を確認し、説明の信頼性を担保した。

まとめ

本研究は、(1) 時系列・異種混合グラフに基づく影響力ランキング予測の追試実装と評価、(2) 特徴量・エッジを対象とするマスク最適化型説明 (importance + score impact) の導入、(3) 月次比較可能な形での要因提示と集約による一般性分析、を行った。実務的には、予測スコアに加え「根拠（要因候補）」を提示することで、施策立案や候補者選定の納得感・再現性向上に寄与することが期待される。今後は、説明の安定性（初期値・ハイパーパラメータに対する再現性）、基準値設定の依存性、および特徴量とエッジの相互作用をより直接に扱う評価指標・可視化の整備が課題である。