

修士論文概要書

Summary of Master's Thesis

Date of submission: 02/29/2026

| | | | | | |
|----------------------------|-----------------------------|---------------------------|------------|-----------------|------|
| 専攻名(専門分野) Department | 電気・情報生命 | 氏名 Name | 渡邊 遼真 | 指導教員 Advisor | 村田 昇 |
| 研究指導名 Research guidance | 情報学習システム | 学籍番号 Student ID number | 5324E110-4 | | |
| 研究題目 Title | マルチモーダルな GNN における説明可能な影響力予測 | | | | |

研究背景

近年、スマートフォンおよびSNSの普及によりデジタルマーケティング市場は拡大しており、特にインフルエンサーマーケティングは企業の認知獲得や購買行動促進において重要な施策となっている。しかし、著名なトップインフルエンサーは起用コストが高騰し、競合との獲得競争も激しいため、早期に有望な人材を発掘し中長期で育成・契約する「青田買い」が実務上の鍵となる。

この意思決定を支えるため、SNS上の行動ログを用いて将来の影響力(例:エンゲージメント)を予測し、候補者をランクインする研究が進んでいる。一方で、多くの深層学習モデルは高精度でも予測プロセスがブラックボックスになりやすく、「なぜその人物が伸びると予測されたのか」という根拠が得られない。実務では、単に予測スコアが高いだけでは施策に結びつかず、投稿頻度・内容・関係性など、具体的に何が成長のドライバとなっているのかを説明可能な形で提示することが求められる。

そこで本研究は、時系列かつ異種混合(マルチモーダル)データに基づく影響力予測モデルに対して、予測と整合する説明を付与する枠組みを構築し、その妥当性と有用性を検証することを目的とする。

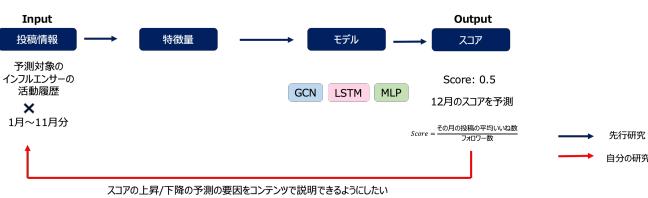


図 1: 本研究の位置付け(予測モデルと説明手法の統合、および月次比較可能な寄与分析)

問題設定

本研究では、Instagramの投稿データ(画像・キャプション・ハッシュタグ等)とユーザー間の関係性(例:メンションやコメントの共起)を用い、月次の異種混合グラフ列を構築する。各時刻 t におけるグラフを

$$G_t = (V_t, E_t, \phi), \quad X_t \in \mathbb{R}^{|V_t| \times d}$$

とする。ここで V_t はノード集合(ユーザー、タグ、オブジェクト等)、 E_t はエッジ集合(例:ユーザー-タグ、ユーザー-メンションなど)、 ϕ はノード/エッジのタイプを表す。 X_t はノード特徴行列であり、数値特徴(投

稿数・投稿間隔・過去エンゲージメント統計)に加え、画像・テキストから抽出した特徴(例:画像輝度やテキスト長)など、マルチモーダル特徴を含む。

タスクは、過去 T 期間における入力 $\{(G_{t-T+1}, X_{t-T+1}), \dots, (G_t, X_t)\}$ から、次期における各ユーザー u の影響力スコア \hat{y}_u を推定し、上位ユーザーをランクインすることである。本研究の目的は値の回帰精度よりも「有望ユーザーの上位抽出」であるため、学習は Learning to Rank として定式化し、順位の整合性を直接最適化する。

なお、本データセットは完全なフォロー関係を含まないため、関係性はメンション等の代替指標により近似する。したがって、構築されるネットワークは「眞の社会関係」を完全に反映するものではなく、観測可能な相互作用に基づく近似である。本研究ではこの制約を明示した上で、予測と説明の枠組みの検証を行う。

提案手法

本研究は、(1) 時系列・異種混合グラフに基づく影響力予測(InfluencerRank型)と、(2) 最適化ベースのマスク学習による説明(MaskOpt)を統合する枠組みを提案する。目的は、単に「誰が伸びるか」を当てるだけでなく、「なぜ伸びると判断したのか」を特徴量および関係性(エッジ)レベルで提示し、月次比較可能な形に整えることである。

(1) 予測モデル: InfluencerRank型 各月の異種混合グラフ G_t に対してGNN(例:GCN)を適用し、ユーザー u の表現 $h_{u,t}$ を得る。

$$h_{u,t} = \text{GNN}(G_t, X_t; \theta_{\text{gnn}})$$

次に、過去 T 期間の表現列 $\{h_{u,t-T+1}, \dots, h_{u,t}\}$ をRNN(LSTM/GRU)で時系列統合し、隠れ状態 $s_{u,t}$ を更新する。

$$s_{u,\tau} = \text{RNN}(h_{u,\tau}, s_{u,\tau-1}; \theta_{\text{rnn}})$$

さらにTemporal Attentionにより各時刻の重要度 $\alpha_{u,\tau}$ を推定し、コンテキスト表現 $c_u = \sum_{\tau} \alpha_{u,\tau} s_{u,\tau}$ を得る。最後にMLPで将来スコア \hat{y}_u を出力し、このスコアでランクインを作る。この構成により、「どの月の状態が予測に効いたか」を注意重みとして解釈でき、後述の説明手法とも自然に接続できる。

(2) 説明手法: End-to-End マスク最適化 (MaskOpt) 予測モデルを固定した上で、説明対象ユーザー u と説

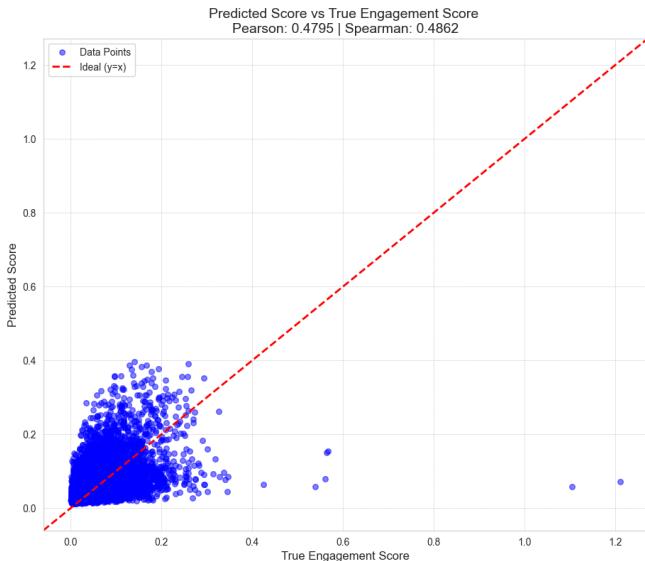


図 2: 集約例: importance ヒートマップ (プレースホルダ).

明対象時刻 (または時刻集合) を定め, 入力要素に連続値マスクを導入する. 具体的には, (i) ノード特徴量に対するマスク m^{feat} , (ii) 近傍エッジに対するマスク m^{edge} を学習し, マスク後の入力でも予測が大きく変化しない (忠実性) 一方で, マスクが少数要素に集中する (簡潔性) ように最適化する. 概念的には以下の目的関数を最小化する:

$$\mathcal{L} = \underbrace{\mathcal{L}_{\text{fidelity}}(\hat{y}_u^{\text{masked}}, \hat{y}_u^{\text{orig}})}_{\text{予測保持}} + \lambda_1 \|m^{\text{feat}}\|_1 + \lambda_2 \|m^{\text{edge}}\|_1$$

最適化後のマスク値を重要度 (importance) として用いる. 重要度は「どの要素が選ばれたか」を表すが, 符号 (スコアを増やす/減らす方向) を含まないため, 重要とされた要素を基準値へ置換したときの予測スコア差分を符号付き影響度 (score impact) として算出する. これにより, 「何が重要か (importance)」と「どう効くか (score impact)」を分離して提示できる. なお, score impact は局所的な反実仮想量であり, 因果効果の断定は行わない.

(3) 集約による一般性の分析 個別説明は有用だが, 実務では「一般に効く要因」と「その人だけの要因」を区別したい. そこで, 上位ユーザー群の importance や score impact を集約し, 特徴量 (および近傍タイプ) ごとに統計量 (平均・分散・上位出現率) を算出する. これをヒートマップ等で可視化することで, 共通因子と局所因子を整理し, 戰略立案に接続可能な形で提示する.

解析例

(1) 予測精度 (定量) 表 1 に主要指標を示す. InfluencerRank 型モデルは単純ベースラインを上回り, 将来有望ユーザーの上位抽出に有効であることを確認した. (※数値は本文の表と完全一致する値に置換すること.)

(2) 説明 (定性+忠実性) MaskOpt により重要特徴量・重要近傍が少数にまとまり, ユーザーごとに寄与

表 1: 予測性能 (例: 12 月テスト).

| 手法 | NDCG@50 | RBP(0.95) |
|-----------------------|---------|-----------|
| 提案 (InfluencerRank 型) | 0.xx | 0.xx |
| ベースライン | 0.xx | 0.xx |
| ランダム | 0.xx | 0.xx |

要因が異なることを確認した. 例えば, 投稿頻度・投稿間隔に関する統計が重要となるユーザーが存在する一方で, テキスト量や過去履歴, 特定近傍との相互作用が支配的となるユーザーも観測された. また, 上位要素の置換により score impact の符号・大きさがモデル出力の変化と整合する傾向が確認され, 説明が単なる可視化ではなく予測挙動に結びついていることが示唆された. sanity check では学習信号を破壊すると説明の一貫性が低下し, 説明がモデル内部の学習結果に依存していることが確認された.

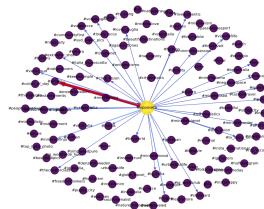


図 3: 左

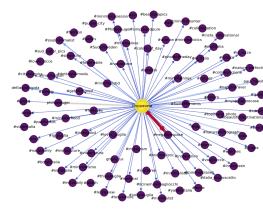


図 4: 右

1月、3月のエッジ重要度可視化結果を図 3, 図 4 に示す。

(3) 一般性 (共通/個別) の可視化 集約結果から,多くのユーザーに共通して重要となる要因 (例: 活動量・投稿間隔) と, 特定ユーザー群に局所的に重要となる要因 (例: 特定カテゴリのタグや近傍関係) が併存することが分かった. さらに月次で重要要因が変化する傾向も観測され, 時系列として説明を比較する必要性が示唆された. これにより, 青田買い意思決定において「一般則」と「個別戦略」を併せて提示できる可能性が得られた.

まとめ

本研究は, (1) 時系列・異種混合グラフに基づく影響力ランキング予測の追試実装と評価, (2) 特徴量・エッジを対象とするマスク最適化型説明 (importance + score impact) の導入, (3) 月次比較可能な形での要因提示と集約による一般性分析, を行った. 実務的には, 予測スコアに加え「根拠 (要因候補)」を提示することで, 施策立案や候補者選定の納得感・再現性向上に寄与することが期待される. 今後は, 説明の安定性 (初期値・ハイパーパラメータに対する再現性), 基準値設定の依存性, および特徴量とエッジの相互作用をより直接に扱う評価指標・可視化の整備が課題である.